

Dokumentacja

Metody Inteligencji Obliczeniowej

Analiza sentymentu tweetów Donalda Trumpa



Wydział Fizyki i Informatyki Stosowanej

Martyna Lach
Julia Mucha
Piotr Waszak

015.06.2026

Spis treści

1	Cel projektu	2
2	Dane i generowanie etykiet	2
2.1	Zbiór danych	2
2.2	Automatyczne generowanie etykiet	3
2.3	Rozkład klas emocjonalnych	3
3	Zastosowane metody	5
3.1	DistilBERT + MLP (frozen)	5
3.2	DistilBERT Fine-tuned (end-to-end)	5
3.3	SBERT + MLP	6
3.4	GloVe + BiLSTM	6
3.5	Zero-Shot BART	6
3.6	TF-IDF + Logistic Regression	6
4	Wyniki eksperymentów	7
4.1	Porównanie skuteczności modeli	7
4.2	Analiza skuteczności dla poszczególnych klas	8
4.3	Analiza błędów klasyfikacji	9
5	Analiza SHAP	11
5.1	Modele oparte na embeddingach: DistilBERT + MLP i SBERT + MLP	12
5.2	Model TF-IDF + Logistic Regression	14
5.3	Najważniejsze obserwacje	16
6	Dyskusja wyników	16
6.1	Dlaczego modele sekwencyjne i fine-tuned przewyższają zamrożone embed- dingi?	16
6.2	Dlaczego model Zero-Shot BART osiągnął tak słabe wyniki?	16
6.3	Najtrudniejsze emocje do rozpoznania	17
6.4	Ograniczenia przeprowadzonych eksperymentów	17
7	Wnioski	18

1 Cel projektu

Zadanie projektowe

- analiza tweetów Donalda Trumpa ze zbioru Trump Tweets,
- automatyczna klasyfikacja emocji zawartych w tweetach,
- porównanie różnych metod reprezentacji tekstu i modeli klasyfikacyjnych,
- interpretacja działania modeli z wykorzystaniem metody SHAP.

Główny problem

Zbiór danych nie zawierał gotowych etykiet emocji, dlatego konieczne było opracowanie własnej procedury ich generowania. Dodatkowym wyzwaniem była specyfika tweetów, które są krótkie, często nieformalne oraz mogą zawierać ironię, sarkazm lub odniesienia polityczne.

Zakres pracy

W ramach projektu przygotowano automatyczny system etykietowania tweetów, a następnie porównano kilka podejść do klasyfikacji emocji:


- DistilBERT + MLP,
- DistilBERT (end-to-end),
- SBERT + MLP,
- GloVe + BiLSTM,
- Zero-Shot BART,
- TF-IDF + Logistic Regression.

Na końcu przeprowadzono analizę interpretowalności modeli z wykorzystaniem SHAP.

2 Dane i generowanie etykiet

2.1 Zbiór danych

Do przeprowadzenia eksperymentów wykorzystano zbiór *Trump Tweets* zawierający 43,352 wpisy opublikowane przez Donalda Trumpa (<https://www.kaggle.com/datasets/austinreese/trump-tweets>).



Rysunek 1: Rozkład długości tweetów.

Na rysunku 1 przedstawiono rozkład długości tweetów. Średnia długość wpisu wyniosła około 121 znaków (20,7 słowa), co jest charakterystyczne dla krótkich form publikowanych w serwisie Twitter.

2.2 Automatyczne generowanie etykiet

Ze względu na brak ręcznie przygotowanych etykiet emocjonalnych opracowano własny system automatycznego etykietowania danych.

Proces przypisywania etykiet miał charakter hierarchiczny:


1. NRC Emotion Lexicon,
2. wykrywanie sarkazmu z wykorzystaniem VADER,
3. wykrywanie patriotyzmu na podstawie słów kluczowych,
4. przypisanie klasy neutral.

W pierwszym kroku wykorzystywano NRC Emotion Lexicon, który przypisuje słowom osiem podstawowych emocji: anger, fear, joy, sadness, disgust, surprise, anticipation oraz trust. Następnie stosowano dodatkowe reguły heurystyczne wykrywające sarkazm oraz odniesienia patriotyczne.


2.3 Rozkład klas emocjonalnych

Ostatecznie uzyskano zbiór obejmujący jedenaście klas emocjonalnych:

angry, fearful, joyful, sad, disgusted, surprised, enthusiastic, trusting, sarcastic, patriotic oraz neutral.



Rysunek 2: Rozkład klas emocjonalnych w zbiorze danych.



Rysunek 3: Rozkład klas emocjonalnych w zbiorze danych.

Jak pokazano na rysunku 2, zbiór danych jest niezbilansowany. Najliczniejszą klasę stanowią tweety neutralne (30,5%), natomiast klasy disgusted oraz surprised obejmują odpowiednio około 1,0

3 Zastosowane metody

W celu oceny różnych sposobów reprezentacji tekstu oraz klasyfikacji emocji przeprowadzono eksperymenty z wykorzystaniem pięciu podejść opartych na nowoczesnych metodach przetwarzania języka naturalnego. Zastosowane modele różniły się zarówno sposobem reprezentacji tweetów, jak i architekturą klasyfikatora.

Tabela 1: Porównanie zastosowanych podejść.

Model	Reprezentacja	Klasyfikator
DistilBERT + MLP	CLS (768)	Residual MLP
DistilBERT FT	Tokeny + CLS (768)	DistilBERT (end-to-end)
SBERT + MLP	Sentence Embedding (384)	Residual MLP
GloVe + BiLSTM	Token Embeddings (200)	BiLSTM + Attention
Zero-Shot BART	Reprezentacja BART	NLI
TF-IDF + LR	TF-IDF	Logistic Regression

3.1 DistilBERT + MLP (frozen)

Pierwsze podejście wykorzystywało embeddingi generowane przez model DistilBERT. Dla każdego tweeta pobierano reprezentację tokenu CLS o wymiarze 768, która stanowiła zagregowany opis całej wypowiedzi. Wagi modelu DistilBERT pozostawały zamrożone podczas treningu — model pełnił wyłącznie rolę ekstraktora cech.

Embeddingi były następnie przekazywane do wielowarstwowej sieci neuronowej typu MLP (Multi-Layer Perceptron) wyposażonej w połączenia rezydualne (Residual Connections). Zastosowanie połączeń rezydualnych umożliwia stabilniejszy trening głębszych sieci poprzez ułatwienie propagacji gradientów oraz ograniczenie problemu zanikania gradientu.

Architektura składała się z warstwy projekcji wejścia, dwóch bloków rezydualnych wykorzystujących funkcję aktywacji GELU oraz końcowej warstwy klasyfikacyjnej przewidującej jedną z jedenastu klas emocjonalnych.

3.2 DistilBERT Fine-tuned (end-to-end)

Drugie podejście stanowiło rozszerzenie pierwszego — zamiast zamrożonych embeddingów przeprowadzono pełny fine-tuning modelu DistilBERT wraz z klasyfikatorem. Wagi transformera były aktualizowane podczas treningu, co pozwala modelowi dostosować reprezentacje do specyfiki klasyfikacji emocji w tweetach.

Model przyjmował na wejściu tokeny (input_ids oraz attention_mask) i przekazywał reprezentację tokenu CLS do prostszej głowy klasyfikacyjnej: Dropout → Linear(768, 256) → GELU → Dropout → Linear(256, 11). Ze względu na znacznie wyższy koszt obliczeniowy fine-tuning trening przeprowadzono na podzbiorze 12 000 próbek przez 4 epoki z

early stopping (patience = 2), z oddzielnymi wartościami learning rate dla warstw transformerów (3×10^{-5}) i głowy klasyfikacyjnej (3×10^{-4}).

3.3 SBERT + MLP

Trzecie podejście oparto na modelu Sentence-BERT (SBERT), wykorzystując wariant all-MiniLM-L6-v2. W przeciwieństwie do klasycznego BERT-a, model ten został zaprojektowany do generowania reprezentacji całych zdań i zachowywania podobieństwa semantycznego pomiędzy wypowiedziami.

Każdy tweet reprezentowany był przez wektor o wymiarze 384. Następnie zastosowano tę samą architekturę klasyfikatora MLP z połączeniami rezydującymi, co w przypadku modelu DistilBERT. Dzięki temu możliwe było bezpośrednie porównanie jakości obu rodzajów embeddingów przy identycznej architekturze klasyfikacyjnej.

3.4 GloVe + BiLSTM

Czwarte podejście wykorzystało klasyczne embeddingi GloVe wytrenowane na danych z serwisu Twitter (glove-twitter-200). W przeciwieństwie do modeli transformerowych embeddingi GloVe są statyczne i nie zależą od kontekstu występowania słowa.

Sekwencje tokenów były przetwarzane przez dwukierunkową sieć LSTM (BiLSTM), która analizowała tekst zarówno od początku do końca, jak i w kierunku przeciwnym. Pozwala to lepiej modelować zależności występujące w zdaniu.

Dodatkowo zastosowano mechanizm Additive Attention, którego zadaniem było przypisanie większej wagi najważniejszym fragmentom tweeta. Dzięki temu model mógł koncentrować się na słowach szczególnie istotnych dla określenia emocji, takich jak wyrażenia pozytywne, negatywne lub nacechowane politycznie.

Ostateczna reprezentacja uzyskana przez mechanizm uwagi była przekazywana do warstwy klasyfikacyjnej przewidującej jedną z badanych emocji.

3.5 Zero-Shot BART

Piąte podejście stanowił model facebook/bart-large-mnli wykorzystany w trybie klasyfikacji zero-shot. W odróżnieniu od pozostałych metod model nie był trenowany na zbiorze tweetów Donalda Trumpa.

Klasyfikacja realizowana była poprzez mechanizm Natural Language Inference (NLI). Dla każdego tweeta model oceniał prawdopodobieństwo przypisania do każdej z badanych emocji na podstawie zdań opisujących poszczególne klasy.

Podejście zero-shot stanowiło punkt odniesienia pozwalający ocenić, jak dobrze gotowy model językowy radzi sobie z analizą emocji bez dodatkowego procesu uczenia na danych projektowych.

3.6 TF-IDF + Logistic Regression

Oprócz modeli neuronowych wykorzystano również klasyczne podejście oparte na reprezentacji TF-IDF (Term Frequency – Inverse Document Frequency) oraz regresji logistycznej.

nej.

W pierwszym kroku każdy tweet został przekształcony do wektora TF-IDF opisującego częstość występowania słów w dokumencie względem całego korpusu. Reprezentacja ta pozwala uwzględnić znaczenie słów charakterystycznych dla danego tekstu przy jednoczesnym ograniczeniu wpływu bardzo często występujących wyrazów.

Następnie wykorzystano wieloklasową regresję logistyczną, która dla każdej klasy emocjonalnej estymowała prawdopodobieństwo przypisania tweeta do danej kategorii. Model ten stanowił klasyczny punkt odniesienia dla bardziej zaawansowanych metod opartych na embeddingach oraz sieciach neuronowych.

Dodatkową zaletą tego podejścia jest wysoka interpretowalność. Ponieważ każda cecha odpowiada bezpośrednio konkretnemu słowu lub tokenowi, możliwe jest przeprowadzenie szczegółowej analizy wpływu poszczególnych słów na decyzje modelu przy użyciu metody SHAP.

4 Wyniki eksperymentów


4.1 Porównanie skuteczności modeli

Tabela 2 przedstawia wartości Accuracy oraz Macro F1 uzyskane przez analizowane modele. Accuracy określa odsetek poprawnie sklasyfikowanych przykładów, natomiast Macro F1 uwzględnia skuteczność dla każdej klasy niezależnie od jej liczności, dzięki czemu lepiej odzwierciedla jakość klasyfikacji w przypadku niezbalansowanych danych.

Tabela 2: Porównanie skuteczności modeli.

Model	Accuracy	Macro F1	F1 Weighted
DistilBERT + MLP (frozen)	0.270	0.193	0.290
SBERT + MLP	0.316	0.247	0.330
DistilBERT Fine-tuned	0.503	0.431	0.520
GloVe + BiLSTM	0.509	0.431	0.530
Zero-Shot BART	0.132	0.121	0.140
TF-IDF + Logistic Regression*	0.650	0.480	0.630

* Ewaluacja na losowym podziale 80/20 zamiast stratyfikowanego 70/15/15 stosowanego przez pozostałe modele — wyniki nie są w pełni porównywalne.



Rysunek 4: Porównanie skuteczności analizowanych modeli.


Najwyższą skuteczność osiągnął model TF-IDF + Logistic Regression (Accuracy 0.650, Macro F1 0.480), jednak wynik ten należy interpretować z ostrożnością ze względu na różnice w procedurze ewaluacji opisane w przypisie do tabeli. Dodatkowo TF-IDF posiada strukturalną przewagę wynikającą ze sposobu etykietowania: etykiety NRC generowane są na podstawie obecności konkretnych słów w tekście, a model liniowy operuje na tych samych cechach leksykalnych.

Wśród modeli neuronowych najlepsze wyniki osiągnęły *ex aequo* DistilBERT Fine-tuned oraz GloVe + BiLSTM, uzyskując Accuracy odpowiednio 0.503 i 0.509 oraz Macro F1 równą 0.431 dla obu modeli. Wynik DistilBERT Fine-tuned jest szczególnie istotny, ponieważ uzyskano go na podzbiorze zaledwie 12 000 próbek przy 4 epokach treningu — co wskazuje na potencjał tego podejścia przy pełnym zbiorze danych.

Modele oparte na zamrożonych embeddingach (DistilBERT + MLP, SBERT + MLP) wypadły wyraźnie słabiej, z Macro F1 poniżej 0.25. Najsłabsze rezultaty uzyskał model Zero-Shot BART, który nie był trenowany na analizowanym zbiorze i pełnił jedynie rolę punktu odniesienia.

4.2 Analiza skuteczności dla poszczególnych klas

Sama wartość Accuracy nie pozwala określić, jak dobrze modele radzą sobie z poszczególnymi emocjami. W tym celu przeanalizowano wartości F1-score dla każdej klasy osobno.



Rysunek 5: Wartości F1-score dla poszczególnych klas emocjonalnych.

Na rysunku 5 przedstawiono wartości F1-score uzyskane dla poszczególnych klas emocjonalnych.

Najlepiej rozpoznawaną klasą była *neutral*, dla której wszystkie modele osiągały relatywnie wysokie wartości F1-score. Dobre wyniki uzyskano również dla klas *joyful* oraz *patriotic*. Emocje te charakteryzują się stosunkowo wyraźnym i powtarzalnym słownictwem, co ułatwia ich identyfikację.

Znacznie większe trudności sprawiały klasy *disgusted*, *surprised* oraz *sarcastic*. Dla tych emocji wszystkie analizowane modele osiągały niskie wartości F1-score, często nieprzekraczające 0.2. Szczególnie trudna okazała się klasa *disgusted*, która była jednocześnie jedną z najmniej licznych klas w całym zbiorze danych.


Widoczna zależność pomiędzy liczebnością klasy a jakością klasyfikacji sugeruje, że niezbalansowany charakter zbioru danych miał istotny wpływ na uzyskane wyniki. Warto zaznaczyć, że zastosowana stratyfikacja podczas podziału danych zapewniła jedynie zachowanie proporcji klas w zbiorach treningowym i testowym, nie eliminując problemu nierównowagi.

Jednocześnie niektóre emocje, takie jak *sarcastic*, pozostają trudne do rozpoznania niezależnie od liczby przykładów, ponieważ ich poprawna identyfikacja często wymaga uwzględnienia szerszego kontekstu wypowiedzi.


Wynik ten jest zgodny z rozkładem danych przedstawionym wcześniej. Klasy posiadające niewielką liczbę przykładów treningowych były znacznie trudniejsze do nauczenia przez modele, co przełożyło się na niższe wartości Precision, Recall oraz F1-score.

4.3 Analiza błędów klasyfikacji

Aby lepiej zrozumieć źródła błędów klasyfikacyjnych, przeanalizowano macierze pomyłek dla dwóch najlepszych modeli neuronowych: GloVe + BiLSTM oraz DistilBERT Fine-tuned.



Rysunek 6: Macierz pomyłek dla modelu GloVe + BiLSTM.



Rysunek 7: Macierz pomyłek dla modelu DistilBERT Fine-tuned.

Macierz pomyłek modelu GloVe + BiLSTM (rysunek 6) pokazuje, że model najskuteczniej rozpoznaje klasy licznie reprezentowane w zbiorze danych, takie jak *neutral*, *joyful*, *angry* oraz *trusting*. Klasy rzadkie (*disgusted*, *surprised*, *sarcastic*) są rozpoznawane z wysokim recall, ale niską precision — model przewiduje je zbyt często i generuje dużo fałszywych alarmów.

DistilBERT Fine-tuned (rysunek 7) prezentuje jakościowo inny wzorec błędów. Przekątna jest wyraźna dla wszystkich klas, w tym trudnych — *disgusted* (14 poprawnych predykcji), *sarcastic* (33) i *surprised* (10). Popełniane pomyłki są semantycznie uzasadnione: *trusting* → *joyful* (40 przypadków), *angry* → *sad* (44) — model myli emocje bliskie znaczeniowo, a nie losowe klasy jak modele zamrożone.

Analiza obu macierzy wskazuje, że głównym źródłem błędów była zarówno nierównowaga klas, jak i semantyczne podobieństwo niektórych emocji, których granice nie są jednoznaczne nawet dla człowieka.

5 Analiza SHAP

Jednym z celów projektu było zbadanie interpretowalności zastosowanych modeli. W tym celu wykorzystano metodę SHAP (SHapley Additive exPlanations), która pozwala określić


wpływ poszczególnych cech wejściowych na decyzję klasyfikatora.

Analizę przeprowadzono dla trzech istotnie różnych podejść: modeli opartych na zamrożonych embeddingach (DistilBERT + MLP oraz SBERT + MLP) oraz modelu TF-IDF + Logistic Regression. Pozwoliło to porównać nie tylko skuteczność modeli, lecz również możliwość wyjaśnienia ich decyzji w zależności od rodzaju reprezentacji tekstu.

5.1 Modele oparte na embeddingach: DistilBERT + MLP i SBERT + MLP

W przypadku obu modeli opartych na zamrożonych embeddingach wejściem klasyfikatora były wektory reprezentacji zdania — odpowiednio token CLS o wymiarze 768 dla DistilBERT oraz wektor zdania o wymiarze 384 dla SBERT. SHAP analizował wpływ poszczególnych wymiarów tych reprezentacji wektorowych, a nie konkretnych słów występujących w tweetach.

Wykresy słupkowe średniego bezwzględnego wpływu poszczególnych wymiarów (dostępne w repozytorium jako `shap_bar_DistilBERT_MLP.png` oraz `shap_bar_SBERT_MLP.png`) pokazują, że różne klasy opierają się na różnych zestawach wymiarów, co sugeruje pewien stopień specjalizacji per klasa. Jednocześnie nakładanie się ważnych wymiarów między klasami — np. `dim_594` pojawia się jako istotny zarówno dla klas *angry*, *joyful*, jak i *trusting* w modelu DistilBERT + MLP — wskazuje na brak wyraźnej separacji przestrzeni embeddingów dla zadania klasyfikacji emocji.



Rysunek 8: Najważniejsze cechy według SHAP dla modelu SBERT + MLP dla klasy *angry*.


Jak pokazano na rysunku 8, SHAP identyfikuje grupę wymiarów embeddingu, które mają największy wpływ na przypisanie klasy *angry*. Większość punktów skupia się wokół zera z długimi ogonami w obu kierunkach, co wskazuje na niestabilny i silnie próbkozależny wpływ poszczególnych wymiarów. Możliwe jest określenie względnego znaczenia poszczególnych cech, jednak ich interpretacja pozostaje utrudniona.

Poszczególne wymiary embeddingu nie posiadają jednoznacznego znaczenia semantycznego. W przeciwieństwie do klasycznych cech tekstowych nie można stwierdzić, które konkretne słowa lub konstrukcje językowe odpowiadają za obserwowany wpływ. W rezultacie analiza SHAP pozwala ocenić, które fragmenty reprezentacji wektorowej są istotne dla modelu, ale nie wyjaśnia bezpośrednio mechanizmu podejmowania decyzji.


Wynik ten dobrze ilustruje jedną z głównych cech nowoczesnych reprezentacji embeddingowych. Oferują one bogaty opis semantyczny tekstu, jednak odbywa się to kosztem interpretowalności.

5.2 Model TF-IDF + Logistic Regression

Znacznie bardziej intuicyjne wyniki uzyskano dla modelu TF-IDF + Logistic Regression. W tym przypadku każda cecha odpowiada konkretnemu słowu występującemu w zbiorze danych, dzięki czemu wartości SHAP mogą być interpretowane bezpośrednio w kontekście treści tweetów.



Rysunek 9: Najważniejsze słowa wpływające na klasyfikację klasy *joyful*.



Rysunek 10: Najważniejsze słowa wpływające na klasyfikację klasy *angry*.

Dla klasy *joyful* (rysunek 9) największy pozytywny wpływ miały słowa takie jak *love*, *hope*, *thanks*, *great*, *good* oraz *wonderful*. Wszystkie są naturalnie kojarzone z pozytywnym wydźwiękiem emocjonalnym, co sugeruje, że model nauczył się wykorzystywać intuicyjne sygnały językowe obecne w danych.

Podobną zależność można zaobserwować dla klasy *angry* (rysunek 10). Wysokie dodatnie wartości SHAP uzyskały słowa takie jak *bad*, *fight*, *illegal* czy *vote*. Są to wyrażenia często pojawiające się w kontekście konfliktu, krytyki lub sporów politycznych, a więc naturalnie związane z emocjami negatywnymi.

Interesującą obserwacją jest również fakt, że dla klasy *angry* silnie ujemne wartości SHAP uzyskały słowa *thank*, *thanks*, *great* oraz *best*. Oznacza to, że ich obecność zmniejszała prawdopodobieństwo przypisania tej klasy. Jest to zgodne z intuicją, ponieważ słowa te występowały częściej w tweetach oznaczonych jako *joyful*, *trusting* lub *patriotic*.

W przeciwieństwie do modelu SBERT możliwe było więc nie tylko wskazanie ważnych cech, ale również bezpośrednie zrozumienie, dlaczego model podjął określoną decyzję.

5.3 Najważniejsze obserwacje

Analiza SHAP ujawniła wyraźną różnicę pomiędzy interpretowalnością badanych modeli.

Modele DistilBERT + MLP oraz SBERT + MLP operowały na złożonych reprezentacjach semantycznych tekstu, jednak wpływ poszczególnych wymiarów embeddingu był trudny do przełożenia na język naturalny — niemożliwe było bezpośrednie wskazanie słów odpowiedzialnych za podjętą decyzję. Z kolei model TF-IDF pozwalał zidentyfikować konkretne słowa i bigramy wpływające na klasyfikację każdej z analizowanych emocji, a ich interpretacja była intuicyjna i zgodna z charakterem danej klasy.

Ostatecznie analiza SHAP potwierdziła klasyczny kompromis pomiędzy złożonością reprezentacji tekstu a interpretowalnością modelu: bogatsze semantycznie embeddingi oferują potencjalnie lepszy opis treści, lecz kosztem przejrzystości mechanizmu podejmowania decyzji.

6 Dyskusja wyników

6.1 Dlaczego modele sekwencyjne i fine-tuned przewyższają zamrożone embeddingi?

Jednym z najbardziej interesujących wyników eksperymentów jest wyraźna przewaga modeli GloVe + BiLSTM (Accuracy 0.509) oraz DistilBERT Fine-tuned (Accuracy 0.503) nad modelami wykorzystującymi zamrożone embeddingi transformerowe (DistilBERT + MLP frozen: 0.270, SBERT + MLP: 0.316).

Modele zamrożone operują na reprezentacjach CLS optymalizowanych pod inne zadania — maskowane modelowanie języka (MLM) dla DistilBERT oraz podobieństwo semantyczne zdań dla SBERT — a nie klasyfikację emocji w nieformalnych tekstach twitterowych. Bogatsza wymiarowość przestrzeni embeddingów nie kompensuje tego niedopasowania dziedzinowego.

GloVe + BiLSTM uzyskuje wysoką skuteczność z dwóch niezależnych powodów. Embeddingi `glove-twitter-200` wytrenowane na korpusie tweetów naturalnie kodują skróty, emotikony i nieformalny rejestr językowy charakterystyczny dla badanego zbioru. Architektura BiLSTM z mechanizmem addytywnej uwagi zachowuje lokalny kontekst sekwencyjny — model przypisuje zróżnicowane wagi poszczególnym tokenom zamiast operować na jednym zagregowanym wektorze.

DistilBERT Fine-tuned osiąga porównywalny wynik inną drogą — poprzez odblokowanie wag transformera i dostosowanie reprezentacji CLS do zadania klasyfikacji emocji w trakcie treningu. Wynik ten uzyskano na podzbiorze 12 000 próbek przy zaledwie 4 epokach, co wskazuje że przy pełnym zbiorze i dłuższym treningu podejście to miałoby potencjał do dalszej poprawy.

6.2 Dlaczego model Zero-Shot BART osiągnął tak słabe wyniki?

Najslabsze rezultaty uzyskał model Zero-Shot BART, którego Accuracy wyniosła jedynie 0.132. Wynik ten był znacząco niższy od wszystkich pozostałych metod.

Jednym z powodów może być sposób działania klasyfikacji zero-shot. Model `bart-large-mnli` nie był trenowany do rozpoznawania emocji w tweetach, lecz do zadania Natural Language Inference. Ocenia on, czy zdanie opisujące daną emocję jest zgodne z treścią tweeta. W praktyce oznacza to, że musi samodzielnie interpretować znaczenie etykiet takich jak *patriotic*, *sarcastic* czy *enthusiastic*, mimo że nie były one częścią procesu treningowego.

Dodatkową trudność stanowi specyfika tweetów Donalda Trumpa. Wiele wpisów zawiera jednocześnie elementy kilku emocji, co utrudnia jednoznaczne przypisanie pojedynczej klasy. Przykładowo wypowiedź krytykująca przeciwników politycznych może zawierać zarówno cechy klasy *angry*, jak i *patriotic*.

Wyniki pokazują, że mimo dużych możliwości współczesnych modeli językowych klasyfikacja emocji pozostaje zadaniem silnie zależnym od domeny danych i wymaga dostosowania modelu do konkretnego problemu.

6.3 Najtrudniejsze emocje do rozpoznania

Analiza wartości F1-score dla poszczególnych klas (rysunek 5) pokazuje, że poziom trudności klasyfikacji był bardzo nierównomierny.

Najlepiej rozpoznawaną klasą była *neutral*, dla której wszystkie modele osiągały relatywnie wysokie wartości F1-score. Dobre wyniki uzyskano również dla klas *joyful* oraz *enthusiastic*. Emocje te charakteryzują się stosunkowo wyraźnym i powtarzalnym słownictwem, co ułatwia ich identyfikację.

Widoczny jest wyraźny podział na dwie grupy modeli. DistilBERT Fine-tuned i GloVe + BiLSTM uzyskują akceptowalne F1 nawet dla klas trudnych: *disgusted* odpowiednio 0.41 i 0.18, *sarcastic* 0.36 i 0.28. Modele zamrożone (DistilBERT + MLP, SBERT + MLP) praktycznie nie rozpoznają tych klas, uzyskując F1 poniżej 0.10.

Klasa *sarcastic* pozostaje trudna pomimo wyższej liczebności niż *disgusted*. Etykiety *sarcastic* generowane są przez heurystykę opartą na negacji i analizie VADER, której modele operujące na gęstych embeddingach nie odtwarzają równie skutecznie co TF-IDF + Logistic Regression działający bezpośrednio na słowach.

6.4 Ograniczenia przeprowadzonych eksperymentów

Interpretując uzyskane wyniki należy pamiętać, że analizowany zbiór nie zawierał ręcznie przygotowanych etykiet emocjonalnych. Wszystkie klasy zostały wygenerowane automatycznie na podstawie słowników emocji i dodatkowych reguł heurystycznych.

Oznacza to, że część wyników odzwierciedla skuteczność odtwarzania procesu etykietowania, a niekoniecznie rzeczywistego rozpoznawania emocji przez modele. Widać to szczególnie w analizie SHAP dla modelu TF-IDF, gdzie największy wpływ na decyzje klasyfikatora miały słowa bezpośrednio związane z przypisywaniem etykiet.

Pomimo tego ograniczenia przeprowadzone eksperymenty pozwoliły porównać kilka istotnie różnych podejść do reprezentacji tekstu oraz pokazały, jak zmienia się interpretowalność modeli wraz ze wzrostem ich złożoności.

7 Wnioski

Celem projektu było zbudowanie modelu analizy emocji dla tweetów Donalda Trumpa oraz zbadanie interpretowalności różnych podejść do reprezentacji tekstu przy użyciu metody SHAP.

Na podstawie przeprowadzonych eksperymentów można sformułować następujące wnioski:

1. **Najwyższą skuteczność osiągnął model TF-IDF + Logistic Regression**, uzyskując Accuracy równą 0.650 oraz Macro F1 równą 0.480.
2. **Spośród modeli neuronowych najlepsze wyniki uzyskał model GloVe + BiLSTM z mechanizmem Attention** (Accuracy = 0.518, Macro F1 = 0.443), przewyższając modele wykorzystujące zamrożone embeddingi transformerowe.
3. **Klasyfikacja emocji okazała się szczególnie trudna dla klas rzadkich**. Najniższe wartości F1-score uzyskano dla emocji *disgusted*, *surprised* oraz *sarcastic*, podczas gdy najlepiej rozpoznawane były klasy *neutral*, *joyful* i *patriotic*.
4. **Analiza SHAP potwierdziła wyraźną różnicę w interpretowalności pomiędzy modelami**. W przypadku modelu TF-IDF możliwe było bezpośrednie wskazanie słów wpływających na decyzję klasyfikatora, natomiast dla modeli opartych na embeddingach interpretacja ograniczała się do analizy poszczególnych wymiarów reprezentacji wektorowych.
5. **Uzyskane wyniki należy interpretować z uwzględnieniem sposobu tworzenia etykiet**. Zastosowana procedura automatycznej anotacji umożliwiła przygotowanie dużego zbioru treningowego, jednak mogła również wpływać na końcową skuteczność modeli.

Przeprowadzona analiza pokazała, że w badanym problemie klasyczne metody reprezentacji tekstu pozostają konkurencyjne wobec bardziej złożonych podejść neuronowych. Jednocześnie wyniki potwierdzają, że skuteczność modelu zależy nie tylko od zastosowanej architektury, ale również od charakterystyki danych, jakości etykiet oraz stopnia dopasowania reprezentacji tekstu do analizowanej domeny.

W przyszłych pracach warto rozważyć wykorzystanie ręcznie anotowanego zbioru danych oraz pełny fine-tuning modeli transformerowych. Pozwoliłoby to dokładniej ocenić potencjał nowoczesnych modeli językowych w zadaniu klasyfikacji emocji oraz ograniczyć wpływ błędów wynikających z automatycznego etykietowania.

Repozytorium

Ze względu na ograniczoną objętość raportu przedstawiono jedynie najważniejsze wyniki oraz przykładowe wizualizacje. Większa analiza eksperymentów, obejmująca dodatkowe wykresy, przebiegi uczenia modeli, macierze pomyłek, wyniki dla poszczególnych klas emocjonalnych oraz kompletne analizy SHAP, została udostępniona w notatniku Jupyter *analiza_wynikow.ipynb* znajdującym się w repozytorium projektu.

Kod źródłowy projektu:

<https://github.com/martynalacha/Trump-Tweet-Emotion-Classififier/tree/main>

Autorzy:

- Martyna Lach
- Julia Mucha
- Piotr Waszak